



DEPARTAMENTO  
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

# TP 1: PageRank

September 11, 2022

Métodos Numéricos

## Grupo 18

Integrante	LU	Correo electrónico
Vekselman, Natán	338/21	natanvek11@gmail.com
Arienti, Federico	316/21	fa.arianti@gmail.com
Barcos, Juan Cruz	463/20	juancruzbarcos@hotmail.com



## Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 11) 4576-3300

<http://www.exactas.uba.ar>

## RESUMEN

El Ranking de Page, *PageRank* [1], es un método propuesto por Sergey Brin y Larry Page —co-fundadores de Google—, para jerarquizar las páginas web del internet, o un subconjunto de las páginas que lo componen. Holísticamente, se puede interpretar como una medición, al largo plazo, del porcentaje de tiempo que un navegante permanecerá en cada uno de los sitios [2].

Desde una perspectiva algorítmica, *PageRank* busca resolver un sistema lineal  $\mathbf{A}x = x$ , donde  $\mathbf{A}$  es una matriz estocástica en columnas [2] y cada una de sus posiciones  $a_{ij}$  representa la probabilidad que un usuario situado en la página  $j$  decida navegar a la página  $i$ .

Este trabajo propone una implementación eficiente del ranking a través del uso de una estructura de matriz acorde al problema, y el empleo de iteradores específicos, para reducir el costo espacial y temporal de la eliminación gaussiana, método utilizado para su resolución.

Se buscará dar una presentación teórica y una evaluación cuantitativa y cualitativa de los resultados de tanto el método propuesto, como de *PageRank* en si.

Palabras clave: *Ranking de Page, Eliminación Gaussiana, Representación de Matrices*

## CONTENIDOS

1. Introducción Teórica	3
1.1. Aridad	3
1.2. El sistema	3
1.3. Representación matricial	4
2. Desarrollo	6
2.1. Implementación	6
2.1.1. Matriz	6
2.1.2. Construir(g, p)	8
2.1.3. Eliminación gaussiana	9
2.1.4. Sustitución inversa	11
2.1.5. normalizar	11
3. Resultados y Discusión	12
3.1. Análisis cuantitativo	12
3.1.1. Error relativo	12
3.1.2. Error absoluto	14
3.2. Análisis cualitativo	15
3.2.1. Escenario 1: Sin Links	15
3.2.2. Escenario 2: Simetría	16
3.2.3. Escenario 3: Todos con uno	17
3.2.4. Escenario 4: Uno con todos	18
3.2.5. Escenario 5: Transitividad en Cadena	19
3.2.6. Escenario 6: Referencias Valiosas	21
4. Conclusiones	24
5. Apéndice	25
5.1. A: $A = pWD + ez^t$	25
5.2. B: $I - pWD$ permite la eliminación gaussiana	27
5.3. C: Alternativas de diseño	30
Referencias	31

## 1. INTRODUCCIÓN TEÓRICA

1.1. **Aridad.** Consideremos primero el dominio y la imagen de PageRank.

DOMINIO: 1. un conjunto de páginas web interconectadas a través de hipervínculos. Podemos considerar este conjunto como un grafo direccionado, donde los nodos son los sitios y los ejes, los links. 2. un parámetro de entrada  $p \in (0, 1)$ , que representa la probabilidad que un usuario decida navegar aleatoriamente a otra página en el grafo. Se puede interpretar como el parámetro de un variable aleatoria de Bernoulli.

IMÁGEN: un vector  $x \in [0, 1]^n$ , donde  $x_i$  representa el Ranking de Page para la  $i$ -ésima página del conjunto de entrada y  $x$  satisface que  $x_i \geq 0 \forall i : 0 \dots n$  y  $\sum_{i=1}^n x_i = 1$ .

Tenemos entonces:

$$(1) \quad \text{PageRank} : G_n \times (0, 1) \longrightarrow [0, 1]^n \quad \forall n \in \mathbb{N}$$

donde  $G_n$  refiere al conjunto de conjuntos de páginas web, interconectadas a través de hipervínculos, con cardinalidad  $n$ .

1.2. **El sistema.** PageRank propone resolver un sistema de ecuaciones para encontrar la relevancia de cada página  $i$  ( $i : 1 \dots n$ ) en  $g \in G_n$ :

$$(2) \quad x_i := \sum_{j=1}^n x_j \cdot \text{Pr}(j \longrightarrow i)$$

donde  $\text{Pr}(j \longrightarrow i)$  es la probabilidad que un usuario situado en la página  $j$  decida ir a la página  $i$ . Se define de la siguiente manera:

$$(3) \quad \text{Pr}(j \longrightarrow i) := \begin{cases} (1-p) \cdot \frac{1}{n} + p \cdot \frac{I_{ij}}{c_j} & \text{si } c_j \neq 0 \\ \frac{1}{n} & \text{si no} \end{cases}$$

con  $I_{ij} = 1$  si y sólo si existe un hipervínculo de  $j$  a  $i$ , con  $j \neq i$  —y nulo en caso contrario—, y  $c_j = \sum_{i=1}^n I_{ij}$ , la cantidad de links salientes de  $j$ . La restricción  $j \neq i$  será para evitar que se consideren auto-referencias en el ranking.

Notemos que  $\text{Pr}(j \longrightarrow i)$  se puede interpretar de la siguiente manera: un navegante situado en la página  $j$  decidirá con probabilidad  $p$  acceder a uno de los links del sitio y con probabilidad  $1-p$  saltar a otra página del conjunto. En ambos casos, deberá luego decidir uniformemente sobre el total disponible, y terminará eligiendo a  $i$  con una probabilidad de  $\frac{I_{ij}}{c_j}$  ó  $\frac{1}{n}$ , respectivamente, acorde a la primer decisión. Si no hay links en la página, siempre saltará de manera uniforme a otra página del conjunto, y elegirá a  $i$  con probabilidad  $\frac{1}{n}$ .

$x_i$ , por su parte, también recibe una interpretación particular: es la probabilidad que para algún momento  $k > K$ , el navegante se encuentre situado en la página  $i$  [4]. Notar que esto es equivalente a decir que  $x_i$  representa la fracción de tiempo, al largo plazo, que un navegante permanecerá en la página  $i$ .

A este modelo se lo conoce como el *modelo del navegante aleatorio*.

**1.3. Representación matricial.** Dado que estamos trabajando con un sistema lineal, será de utilidad considerar la matriz asociada ‘ $\mathbf{A}$ ’ y resolver, equivalentemente,  $\mathbf{A}x = x$ , donde  $x = (x_1, \dots, x_n)^t$ . Definimos entonces:

$$(4) \quad a_{ij} := Pr(j \longrightarrow i)$$

y proponemos que<sup>1</sup>:

$$(5) \quad \mathbf{A} = p\mathbf{W}\mathbf{D} + ez^t$$

donde  $\mathbf{A} \in [0, 1]^{n \times n}$  y  $\forall i, j : 1 \dots n$  se satisface que:

$$e_i = 1$$

$$z_j = \begin{cases} (1-p)/n & \text{si } c_j \neq 0 \\ 1/n & \text{si no} \end{cases}$$

$$w_{ij} = \begin{cases} 1 & \text{si } i \neq j \wedge j \xrightarrow{l} i \\ 0 & \text{si no} \end{cases}$$

$$d_{ij} = \begin{cases} 1/c_j & \text{si } i = j \wedge c_j \neq 0 \\ 0 & \text{si no} \end{cases}$$

La notación  $j \xrightarrow{l} i$  representa que existe un link de la página  $j$  a la página  $i$ , y las filas y columnas de  $\mathbf{W}$ , denominada *matriz de conectividad*, representan —indexadas por posición— las páginas de una web  $g \in G_n$ .

A partir de la Ecuación 5 podemos ver que:

---

<sup>1</sup>Una demostración de esta equivalencia se encuentra en 5.1.

$$\begin{aligned}
\mathbf{A}x &= x \\
(p\mathbf{W}\mathbf{D} + ez^t)x &= x \\
p\mathbf{W}\mathbf{D}x + ez^tx &= x \\
x - p\mathbf{W}\mathbf{D}x &= ez^tx \\
(\mathbf{I} - p\mathbf{W}\mathbf{D})x &= \gamma e
\end{aligned}$$

donde  $\gamma = z^tx$  es un escalar.

Dado que nuestro resultado deberá ser normalizado para cumplir con los requerimientos de la imagen, podemos asumir un  $\gamma$  conveniente [3],  $\gamma = 1$ , tal que el sistema a resolver sea:

$$(6) \quad (\mathbf{I} - p\mathbf{W}\mathbf{D})x = e$$

Notar que La matriz  $\mathbf{I} - p\mathbf{W}\mathbf{D}$  es estocástica en columnas, por lo que permite la aplicación de la eliminación gaussiana sin permutación<sup>2</sup>.

---

<sup>2</sup>Una demostración de este enunciado se encuentra en 5.2.

## 2. DESARROLLO

**2.1. Implementación.** A partir del sistema planteado en la Ecuación 6, proponemos el siguiente método para la resolución de PageRank:

- 1) Construir la matriz  $\mathbf{I} - p\mathbf{WD}$  a partir de alguna representación de  $g \in G_n$  (recordar que  $g$  es un conjunto de páginas web con cardinalidad  $n$ ).
- 2) Triangular la matriz extendida  $(\mathbf{I} - p\mathbf{WD} \mid \mathbf{e})$  mediante eliminación gaussiana, sin pivoteo<sup>3</sup>.
- 3) Resolver la matriz resultante mediante el algoritmo de sustitución inversa.
- 4) Normalizar el resultado.

En código:

---

```

1 proc PageRank(in g: G<n>, in p: real, out x: vector<n>) {
2     /* Pre: 0 < p < 1 */
3     B := construir(g, p) // B = I - pWD
4     e := vector(n, 1)    // e = 1 de dimension n
5     eliminacion_gaussiana(B, e)
6     x := sustitucion_inversa(B, e)
7     normalizar(x)
8     /* Post: x[i] >= 0 para toda i y sum(x) = 1 */
9 }

```

---

ALGORITMO 1. Pseudocódigo para *PageRank*.

De este algoritmo surgen las siguientes preguntas: ¿Cómo representamos las matrices<sup>4</sup>? ¿Cómo construimos  $\mathbf{I} - p\mathbf{WD}$ ? ¿Cómo implementamos la eliminación gaussiana? y ¿Cómo implementamos la sustitución inversa?

**2.1.1. Matriz.** Una representación eficiente de matriz será una que permita aprovechar las cualidades de  $\mathbf{I} - p\mathbf{WD}$ , que tenga un costo mínimo de mantenimiento respecto a sus operaciones elementales y que sea eficiente en el uso de la memoria.

Lo primero a notar son las operaciones fundamentales de la estructura. Desde un punto de vista abstracto, estas son aquellas que la definen como un espacio vectorial y, en el caso de  $\mathbb{R}^{n \times n}$ , como un álgebra:

---

<sup>3</sup>Es decir, nuestra solución no buscará reducir el error numérico de la aritmética de punto flotante —en particular por cancelación catastrófica— por medio de las técnicas de pivoteo parcial o pivoteo completo que se utilizan en algunas implementaciones del algoritmo.

<sup>4</sup>Para este trabajo asumiremos que existe una implementación de vector. Sin embargo, notar que un vector puede ser representado por una matriz  $n \times 1$  ó  $1 \times n$ .

$$\mathbf{A} + \mathbf{B} := (a + b)_{ij} = a_{ij} + b_{ij} \quad \forall i : 1 \dots n, j : 1 \dots m$$

$$\mathbf{A} \cdot \mathbf{B} := (ab)_{ij} = \sum_{k=1}^m a_{ik} b_{kj} \quad \forall i : 1 \dots n, j : 1 \dots q$$

$$\lambda \cdot_{\mathbb{R}} \mathbf{A} := (\lambda a)_{ij} = \lambda a_{ij} \quad \forall i : 1 \dots n, j : 1 \dots m$$

Más allá de las posibles implementaciones —que veremos no hacen falta—, importa destacar el fuerte carácter iterativo (las operaciones y la acción actúan sobre todas las posiciones) y observar que cuando  $a_{ij} = 0$  ó  $b_{ij} = 0$ , el resultado es invariante respecto a al menos uno de los operandos. Desde un punto de vista algorítmico, esto significa que estos casos son redundantes y posiblemente se los pueda omitir (por ejemplo, iterando sólo sobre los elementos no nulos).

Esto es particularmente importante para *PageRank*, donde se espera que una página web tenga pocos links salientes (en relación al total de los sitios) y donde se puede demostrar una tendencia a la localidad de las relaciones [3]. Para un conjunto lo suficientemente grande, podemos suponer que nuestra matriz estará principalmente vacía.

A partir de este breve análisis, proponemos las siguientes estructuras<sup>5</sup>:

$$(7) \quad \text{matriz} := \left\{ \begin{array}{l} n, m : \mathbb{N} \\ \text{datos} : \text{vector} < \text{vector} < \text{par} := \left\{ \begin{array}{l} \text{posición} : \mathbb{N}_0, \\ \text{elemento} : \mathbb{R} \end{array} \right. > > \\ \text{at} : \mathbb{N} \ i \times \mathbb{N} \ j \longrightarrow \mathbb{R} \quad \{0 \leq i < n \wedge 0 \leq j < m\} \\ \text{set} : \mathbb{N} \ i \times \mathbb{N} \ j \times \mathbb{R} \longrightarrow \text{matriz} \quad \{0 \leq i < n \wedge 0 \leq j < m\} \end{array} \right.$$

$$(8) \quad \text{iterador} := \left\{ \begin{array}{l} i, j, \text{pos} : \mathbb{N}_0 \\ p : *matriz \\ \text{at} : \longrightarrow \mathbb{R} \quad \{\text{en\_rango}()\} \\ \text{set} : \mathbb{R} \longrightarrow \text{iterador} \quad \{\text{en\_rango}()\} \\ \text{proximo\_fila} : \longrightarrow \text{iterador} \\ \text{proximo\_columna} : \longrightarrow \text{iterador} \\ \text{en\_rango} : \longrightarrow \text{bool} \end{array} \right.$$

---

<sup>5</sup>Una evaluación en más detalle de la implementación y las alternativas consideradas se encuentra en el Apéndice 5.3.



donde *vector* se refiere a un arreglo de tamaño variable en memoria contigua y *\** designa un puntero.

Esta estructura de matriz mantendrá las siguientes garantías: el tamaño del vector externo siempre equivaldrá a  $n$ , el tamaño de cada vector interno estará acotado por  $m$ , los pares internos estarán ordenados por posición y para cada uno se satisfará que  $0 \leq \text{posición} < n$  y que el elemento es no nulo.

La estructura asociada al iterador, por su parte, satisfará que el iterador es válido si y sólo si  $0 \leq i < n$  y  $0 \leq \text{pos} < \text{largo}(\text{datos}[i])$ , que  $j = (*p).\text{datos}[i][\text{pos}].\text{posicion}$ , y que un iterador válido siempre estará sobre un elemento distinto a cero<sup>6</sup>.

Entre ambas podremos iterar por los elementos no nulos de cada fila en  $\Theta(1)$  —ya que estarán en orden sucesivo en el vector interno— y será eficiente en espacio<sup>7</sup>. Como contrapartida, no será eficiente en la inserción: en el peor caso requerirá mover todos los elementos en una fila (por un costo en  $\Theta(m)$ ).

Una decisión importante a mencionar es que consideraremos nulo a cualquier valor menor a  $1e-4$ . Este valor permite mejores tiempos en la ejecución y mantiene un error en el orden de  $1e-5$  coordenada a coordenada<sup>8</sup>.

2.1.2. *Construir*( $g, p$ ). Dada nuestra representación de matriz, el siguiente paso será construir, a partir de un conjunto de páginas web  $g$  y un valor  $p$ , la matriz  $\mathbf{I} - p\mathbf{WD}$ . Para ello, vamos a adoptar una representación particular de  $g$ :

$$(9) \quad g \in G_n := \left\{ \begin{array}{l} \text{\#páginas : } n, \\ \text{relaciones : } \text{vector} < \text{eje} := \{ i, j : \mathbb{N} > \end{array} \right.$$

donde cada eje representa un hipervínculo de la página  $j$  a la página  $i$  y se satisface que  $0 \leq i, j < n$ .

Proponemos el siguiente algoritmo:

---

```

1 proc construir(in g: G<n>, in p: real, out B: matriz<n, n>) {
2   n := g.#paginas
3   B := identidad(n)    // B = I de dimension n x n
4   ponderar(B, g, p)    // B = I - pWD
5 }
```

---

ALGORITMO 2. Pseudocódigo para *construir*.

---

<sup>6</sup>Sobre el iterador, debemos aclarar que éste se situará en la columna no nula más cercana a la pedida, que el método PROXIMO\_COLUMNA situará al iterador sobre la columna no nula más próxima (en relación a la que se usó para inicializar el iterador originalmente) de la siguiente fila, o continuará si ésta es vacía, y PROXIMO\_FILA situará al iterador sobre el próximo elemento no nulo en la misma fila.

<sup>7</sup>En relación a nuestras expectativas sobre la realidad de PageRank.

<sup>8</sup>La medición de los resultados se encuentra en 3.1.

Notamos que la matriz  $\mathbf{D}$  es diagonal y, por ende, la multiplicación a derecha con  $\mathbf{W}$  equivaldrá a escalar los elementos de cada columna  $W_j$  por  $d_{jj}$ . En el caso de los elementos nulos, la operación será invariante —algo que también sucederá con la multiplicación escalar por  $-p$ —.

Tenemos entonces:

---

```

1 proc identidad(in n: natural, out B: matriz<n, n>) {
2   B := matriz(n, n, 0) // B = 0 de dimension n x n
3   i := 0
4   while i < n {
5     B.set(i, i, 1)
6     i := i + 1
7   }
8 }

```

---

ALGORITMO 3. Pseudocódigo para *identidad*.

---

```

1 proc ponderar(inout B: matriz<n, n>, in g: G<n>, in p: real) {
2   grado := vector(n, 0) // grado = 0 de dimension n
3   i = 0
4   while i < largo(g.relaciones) {
5     eje := g.relaciones[i]
6     grado[eje.j] := grado[eje.j] + 1
7   }
8   while i < largo(g.relaciones) {
9     eje := g.relaciones[i]
10    if eje.i != eje.j {
11      B.set(eje.i, eje.j, -p / grado[eje.j])
12    }
13  }
14 }

```

---

ALGORITMO 4. Pseudocódigo para *ponderar*.

De ambos algoritmos podemos notar que la complejidad de CONSTRUIR estará en  $\Theta(n+r \cdot c)$  donde  $r$  representa la cantidad total de relaciones y  $c$  es el costo de SET. Para nuestra representación, esto equivaldrá a  $\Theta(n + r \cdot n)$  y, como  $r \leq n^2$ , tendremos un peor caso en  $\Theta(n^3)$ . Sin embargo, si  $r \ll n^2$ , se puede esperar un comportamiento mejor que el método ‘directo’ (cuyo costo fijo es  $\Theta(n^3)$  por el producto de matrices).

**2.1.3. Eliminación gaussiana.** El siguiente paso será triangular  $(\mathbf{I} - p\mathbf{W}\mathbf{D} \mid e)$  para obtener un sistema fácil de resolver. Proponemos una versión optimizada de la eliminación gaussiana —para nuestro uso— que se vale de las siguientes observaciones:

- Dada una matriz  $\mathbf{A}$  que permite la eg., el paso  $i$ -ésimo del algoritmo, que modifica la fila  $j$  ( $j > i$ ), es necesario sólo si  $a_{ji} \neq 0$ , ya que sino la operación  $A_j \leftarrow A_j - \frac{a_{ji}}{a_{ii}} \cdot A_i$  es invariante.
- Similarmente,  $A_j \leftarrow A_j - \frac{a_{ji}}{a_{ii}} \cdot A_i$ , requiere operar sólo sobre los elementos no nulos de  $A_i$ .

---

```

1 proc eliminacion_gaussiana(inout A: matriz<n, n>, inout b: vector<n>) {
2     i := 0
3     while i < A.n - 1 {
4         jt := iterador(A, i + 1, i)
5         while jt.en_rango() {
6             if (jt.j == i) { // solo si B.at(i + 1, i) != 0
7                 mij := jt.at() / A.at(i, i)
8                 sumar_fila(A, b, i, jt.i, mij)
9             }
10            jt.proximo_columna()
11        }
12        i := i + 1
13    }
14 }
```

---

ALGORITMO 5. Pseudocódigo para *eliminacion\_gaussiana*.

---

```

1 proc sumar_fila(inout A: matriz<n, n>, inout b: vector<n>,
2               in f1, f2: natural, in c: real) {
3     it := iterador(A, f1, f1)
4     while it.en_rango() {
5         val := B.at(f2, it.j) - c * it.at()
6         B.set(f2, it.j, val)
7         it.proximo_fila()
8     }
9     b[f2] := b[f2] - mij * b[f1]
10 }
```

---

ALGORITMO 6. Pseudocódigo para *sumar\_fila*.

Para no complicar el análisis, podemos estimar que el algoritmo costará  $O(n^2 \cdot k^2)$  en el caso promedio. El  $n^2$  corresponde a la iteración de cada fila  $j$  sobre cada fila  $i$ , dado  $0 \leq i < j < n$ , y  $k$  corresponde a la cantidad de elementos no nulos en la matriz<sup>9</sup>. Dado  $k \leq n$ , el costo de peor caso será  $O(n^4)$ . Sin embargo, mientras  $k < \sqrt{n}$  este método funcionará mejor que la forma tradicional de la eliminación (cuyo costo teórico es  $\Theta(n^3)$ ).

---

<sup>9</sup>Se estima  $k^2$  por SUMAR\_FILA, que itera sobre los elementos no nulos de una fila e incluye una operación de SET.

2.1.4. *Sustitución inversa.* Al igual que en la eliminación gaussiana, aprovecharemos el hecho que  $A_j \leftarrow A_j - \frac{a_{ji}}{a_{ii}} \cdot A_i$  requiere operar sólo sobre los elementos no nulos de  $A_i$ , para lograr un algoritmo en  $\Theta(n \cdot k)$ , con  $k$  la cantidad de elementos no nulos de la matriz:

---

```

1 proc sustitucion_inversa(in A: matriz<n, n>, in b: vector<n>,
2                               out x: vector<n>) {
3     x := vector(A.n, 0) // x = 0 de dimension n
4     i := A.n - 1
5     while i >= 0 {
6         s := 0
7         it := iterador(A, i, i + 1)
8         while it.en_rango() {
9             s := s + it.at() * x[it.j]
10            it.proximo_fila()
11        }
12        x[i] := (b[i] - s) / A.at(i, i)
13        i := i + 1
14    }
15 }
```

---

ALGORITMO 7. Pseudocódigo para *sustitucion\_inversa*.

Nuevamente, el peor caso se dará cuando  $k = n$ .

2.1.5. *normalizar.* Por último, presentaremos un algoritmo estándar para normalizar un vector de tamaño  $n$  en  $\Theta(n)$ :

---

```

1 proc normalizar(inout x: vector<n>) {
2     s := 0
3     i := 0
4     while i < largo(x) {
5         s += x[i]
6         i := i + 1
7     }
8     i := 0
9     while i < largo(x) {
10        x[i] = x[i] / s
11        i := i + 1
12    }
13 }
```

---

ALGORITMO 8. Pseudocódigo para *normalizar*.

### 3. RESULTADOS Y DISCUSIÓN

**3.1. Análisis cuantitativo.** Procederemos a evaluar nuestra implementación de *PageRank* en C++ acorde a los algoritmos propuestos.

**3.1.1. Error relativo.** Medimos el error  $|\mathbf{A}x - x|_1$  en función del valor de  $p$  para cien grafos generados aleatoriamente. En total, obtuvimos 10,000 mediciones<sup>10</sup>.

**METODOLOGÍA.** Se calculó  $x = \text{PageRank}(g, p)$  y se midió el error relativo  $|\mathbf{A}x - x|_1$  para cada uno de los grafos sobre cada valor de  $p$  en el intervalo  $(0, 1)$  de a saltos de 0.01.

Cada caso, representable por una matriz de conectividad  $W \in \{0, 1\}^{100 \times 100}$ , se generó a través del siguiente procedimiento<sup>11</sup>:

- 1) Se eligió la cantidad de ejes ( $e$ ) del sistema de manera uniforme sobre el intervalo  $[0, R \cdot T)$ , donde  $T = 100^2 - 100$  representa el máximo de ejes posibles en un grafo de cien nodos sin auto-direccionamiento y  $R = 1/4$  es un valor arbitrario definido para imitar las características de realidad esperables en un conjunto de páginas web.
- 2) Se pobló una matriz  $W_0 \in \{0, 1\}^{99 \times 100} = 0$  con unos en las primeras ‘e’ posiciones y se utilizó el algoritmo de shuffle de numpy, sobre el rng PCG64, para generar una permutación aleatoria.
- 3) Se expandió la misma con ceros en la diagonal para lograr la matriz  $W \in \{0, 1\}^{100 \times 100}$ .

**OBSERVACIONES.** El experimento tiene como limitaciones principales el tamaño de la muestra (cien grafos distintos) y el método de generación de casos —los mismos no provienen de muestras reales—, que incluye la elección arbitraria del valor  $R$ . Sin embargo, contempla con cierta granularidad todo el espectro de valores posibles para  $p$ , tal que permite conocer el error relativo de los resultados en función de su parámetro ‘libre’.

**RESULTADOS.** El cuadro 1. resume los resultados obtenidos.

mediciones	10000
error relativo promedio	0.00084646
desviación estándar	0.00063764
mínimo	1.7347e-16
25%	0.00034960
50%	0.00075431
75%	0.00121044
máximo	0.00376671

Cuadro 1. datos de resumen del experimento.

<sup>10</sup>El script asociado se puede encontrar en `./experimentos/error_relativo.py`

<sup>11</sup>Se utilizó un valor semilla para facilitar la reproducibilidad.

Podemos observar que el error relativo fue en promedio menor a  $1e - 3$ . De distribuirse uniformemente, esto nos permite suponer que el error relativo de cada puntaje debe estar en el orden de  $1e - 5$ .

La Figura 1. muestra la distribución de los resultados en función del parámetro  $p$ .




FIGURA 1. Error relativo promedio -en base a una norma L1- e intervalo de confianza del 95% para una muestra aleatoria de cien grafos en función de  $p$ .

Notar la progresiva disminución del error a medida que  $p$  se aproxima a 1. Los máximos locales se encuentran en  $p = 0.16$  (0.00101828) y  $p = 0.55$  (0.00117609). El mínimo local en  $p = 0.26$  (0.00056232)<sup>12</sup>.

Si bien el tamaño de la muestra y su método de generación no permiten sacar conclusiones fuertes al respecto de los resultados, sí podemos notar que el valor de  $p$  influye el error relativo. Desde un punto de vista numérico esto tiene sentido, dado que  $p$  reduce la magnitud de los valores sobre los que trabaja el algoritmo. Sin embargo, la forma particular de la distribución del error en función de  $p$  resultó sorpresiva.

A modo de consideración para futuros análisis, podemos mencionar que nuestro método de ‘corte’ —cualquier valor menor a  $1e - 4$  se anula— también debe influir en el error de los resultados.

<sup>12</sup>El cálculo de los picos locales se puede encontrar en `./experimentos/resultados/error_relativo`

3.1.2. *Error absoluto.* Medimos el error  $|x - \hat{x}|_1$  para los casos de test provistos por la cátedra<sup>13</sup>.

El Cuadro 2. resume los resultados.

test	$L_1$	$L_\infty$
test_15_segundos	0.0291137	5.015e-05
test_30_segundos	0.0229572	4.841e-05
test_aleatorio	6.176e-07	2.518e-07
test_aleatorio_desordenado	6.176e-07	2.518e-07
test_completo	0.0	0.0
test_sin_links	0.0	0.0
test_trivial	0.0	0.0

Cuadro 2. Error absoluto en base a la norma  $L_1$  y  $L_\infty$  de los tests.

Podemos observar que hay cierta correlación entre la cantidad de páginas y el error. Esto tiene sentido dado que la norma  $L_1$  es la suma del valor absoluto de las coordenadas. Mientras mayor sea la dimensión, mayor será la cantidad de errores a sumar.

---

<sup>13</sup>El script asociado se puede encontrar en `./experimentos/error_tests.py`. Los resultados coordenada a coordenada se pueden observar en `./experimentos/resultados/error_tests`.

**3.2. Análisis cualitativo.** Para entender en profundidad las propiedades de *PageRank*, decidimos evaluar distintos escenarios ‘simples’ de grafos. Comenzamos por los casos triviales.

**3.2.1. Escenario 1: Sin Links.** Ninguna página tiene un vínculo a ninguna otra. Este es el caso base que el *modelo del navegante aleatorio* busca resolver respecto a modelos anteriores.




FIGURA 2. Una web con seis páginas desvinculadas.

**METODOLOGÍA.** Se generaron cien conjuntos de páginas web sin links donde se varió la cantidad total de sitios (de uno a cien). Se midió el puntaje de cada uno en los rankings obtenidos.

**RESULTADOS.** Observamos que el puntaje de todas las páginas fue igual en cada caso, pero fue decreciendo en función de la cantidad total de nodos.

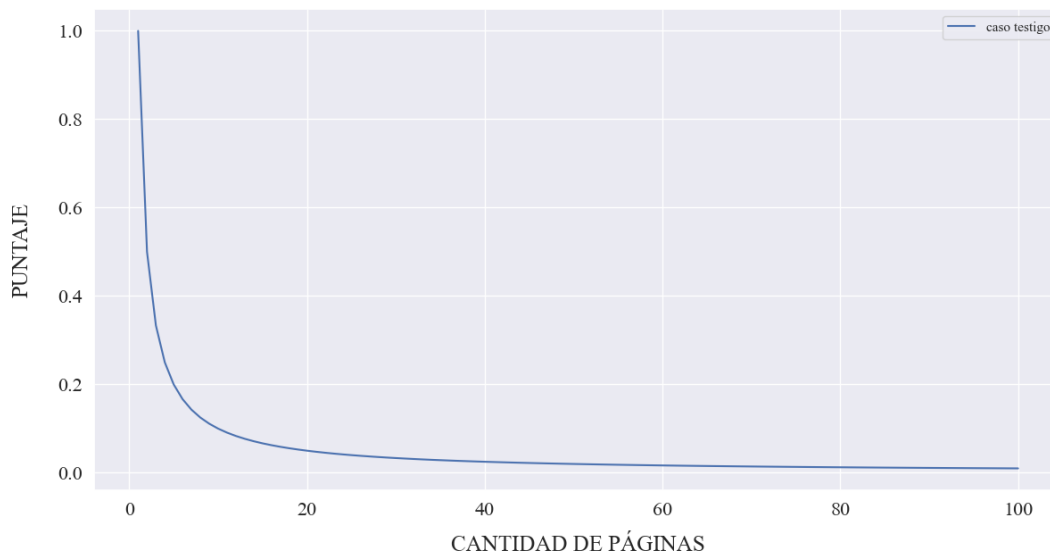


FIGURA 3. El puntaje de una página testigo en función de la cantidad de páginas para conjuntos sin links.



El puntaje obtenido para cada página fue de  $\frac{1}{n}$ . La figura 3. grafica los resultados para un caso testigo. Esto se explica teóricamente: si no hay links en la web, entonces la matriz de conectividad  $\mathbf{W}$  es nula y  $\mathbf{I} - p\mathbf{W}\mathbf{D} = \mathbf{I}$ . Como  $\mathbf{I}x = 1 \implies x_i = 1$ . Al normalizar nos queda que  $x_i = \frac{1}{n} \forall i : 1 \dots n$ .

El resultado es coherente con la interpretación intuitiva del ranking: si ninguna página redirige a ninguna otra, entonces un navegante sólo podrá acceder a los sitios del conjunto de manera aleatoria. El modelo define esta probabilidad de manera uniforme sobre el total de las páginas. A mayor cantidad de páginas, menor la probabilidad que el navegante aleatorio termine en un sitio en particular.

3.2.2. *Escenario 2: Simetría.* Otro escenario trivial es en el que todas las paginas tienen links a todas las demás.




FIGURA 4. Una web simétrica dónde cada nodo apunta al resto.

**METODOLOGÍA.** Para analizar esta situación, se generaron cien casos distintos donde se varió la cantidad de nodos (entre uno y cien) y se mantuvo la simetría de las relaciones. En el primero caso, se compuso una web con un único nodo. Luego, con dos nodos apuntándose mutuamente y así progresivamente hasta llegar a cien nodos donde cada uno apuntó al resto. Se utilizó un valor de  $p$  de 0.85<sup>14</sup>.

**RESULTADOS.** Observamos que el puntaje de cada una de las páginas fue igual para cada caso particular<sup>15</sup> pero que este valor fue decrementando a medida que aumentó la cantidad de sitios. Luego de observar el resultado notamos que para cada  $n$  el valor resultante fue exactamente el mismo que en el caso "sin links".

Esto tiene sentido ya que si todos los nodos se apuntan entre sí, el sistema es totalmente simétrico, y sería ilógico que alguno tenga más importancia que los demás.

Pudimos notar la misma clase de relación, y los exactos mismos resultados, con otras estructuras simétricas. Por ejemplo, en estructuras de referencias circulares<sup>16</sup>.

<sup>14</sup>Según [3] éste es el valor que utiliza Google.

<sup>15</sup>Se puede ver el resultado de los experimentos en `./experimentos/resultados/todos_con_todos`.

<sup>16</sup>Ver `./experimentos/resultados/circular`

3.2.3. *Escenario 3: Todos con uno.* Para esta estructura, tal y como su nombre indica, se enlazó a todas las páginas en el conjunto con una única otra. Se referirá a ésta como la página 'uno'.




FIGURA 5. Una web centralizada, donde todos los nodos señalan a la misma página.

METODOLOGÍA. Se generaron cien casos distintos donde se varió la cantidad de enlaces que conectan con el 'uno' y se midió su puntaje y el de un segundo nodo testigo. Se controló la cantidad de nodos (cien) y se evitaron otros vínculos. Se usó un valor de  $p$  de 0.85.

HIPÓTESIS. Consideramos que el puntaje se comportará de la siguiente forma:

- El 'uno' tendrá un ranking muy cercano a 1, que aumentará de tamaño de manera proporcional a la cantidad de páginas existentes. Estimamos que el crecimiento adoptará una curva similar a una logarítmica.
- Las demás páginas tendrán un ranking muy cercano a 0, que disminuirá en relación al numero de enlaces existentes.




FIGURA 6. El puntaje del nodo 'uno' y de otro sitio testigo para el conjunto, en función de la cantidad de referencias que recibe 'uno'.

RESULTADOS. Observamos que los resultados obtenidos distan un poco de los especulados<sup>17</sup>, ya que, si bien el decrecimiento del resto de las páginas fue de la forma descrita (es difícil observar en el gráfico), el comportamiento del *'uno'* no se comportó de manera logarítmica. Consideramos que es más parecida a alguna variante de  $\sqrt{n}$ . Esto nos llamó la atención.

3.2.4. *Escenario 4: Uno con todos.* Para esta estructura, se propuso el caso inverso al anterior: una única página, que será referenciada nuevamente como *'uno'*, tendrá enlaces salientes hacia todas las demás. Además, cualquier otro tipo de relación será nula. Los enlaces de *'uno'* serán únicamente salientes.




FIGURA 7. Una web muy simétrica, donde todos, excepto *'uno'* poseen el ranking máximo.

METODOLOGÍA. Para analizar esta situación, se generaron cien casos distintos donde se varió la cantidad de enlaces salientes de *'uno'*. De esta forma, vimos la evolución de una web a medida que el *'uno'* va conectando con las demás páginas. Para evaluar los resultados de la evolución, graficamos las variaciones de tres páginas. La *'uno'*, la primer página con la que conecta y la última con la que lo hace.

HIPÓTESIS. Suponemos que se comportará de la siguiente forma:

- La *'uno'* tendrá un ranking significativamente menor que todas las demás páginas, disminuyendo a medida que aumenta el número de páginas. Estimamos que el decrecimiento adopte una curva similar a  $\frac{1}{n}$ .
- Las demás páginas irán disminuyendo su ranking hasta cierto punto, donde alcanzarán un máximo cuando *'uno'* las conecte. Luego, seguirán disminuyendo su ranking hasta que todas posean el mismo, excepto *'uno'*.

RESULTADOS. Observamos que los resultados difieren en gran forma de lo especulado<sup>18</sup>, la disminución de su ranking fue abrupto ni bien se conectó el primer enlace. Por otro lado, las suposiciones hechas para los demás son tal cuál se esperaban. Fue sorpresiva la cantidad de puntaje que recibió el primer testigo al ser el único link referenciado.

<sup>17</sup>Se puede ver el resultado de los experimentos en `./experimentos/resultados/todos_a_uno`.

<sup>18</sup>Se puede ver el resultado de los experimentos en `./experimentos/resultados/uno_a_todos`.




FIGURA 8. El puntaje del nodo ‘uno’ y de dos otros sitios testigos para el conjunto, en función de la cantidad de referencias saliente de ‘uno’.

3.2.5. *Escenario 5: Transitividad en Cadena.* Cómo se transfiere el puntaje de un sitio a otro a medida que se extiende la cadena de páginas intermedias entre ambos<sup>19</sup>.




FIGURA 9. Una cadena de nodos.

Consideramos de interés ver cómo se ve afectado el puntaje de una página al ser apuntada por otra ‘importante’, y cómo varía a medida que empiezan a haber más intermediarios en la relación.

**METODOLOGÍA.** Se generaron cien instancias de test con 200 nodos cada una —para controlar las variaciones del puntaje relacionadas a la inserción de nuevos nodos<sup>20</sup>— y se estableció que las páginas indexadas en el rango (100, 200] apunten a la página 1 y que el resto esté desvinculada. Se utilizó un parametro  $p$  de 0.85.

<sup>19</sup>Se puede ver el resultado de los experimentos en `./experimentos/resultados/transitividad_en_cadena`.

<sup>20</sup>Como se comprobó sucede en el Escenario 1.




FIGURA 10. El puntaje del último eslabón en una cadena de vínculos, en función de su largo. Salvo la primer página, el resto de las páginas en la cadena no tiene otras relaciones.

Se procedió a generar una cadena cuyo tamaño se incrementó en uno en cada instancia sucesiva del test: en la primera, el nodo ‘1’ apuntó al nodo ‘2’; en la segunda, se extendió la cadena y el nodo ‘2’ apuntó al nodo ‘3’; se procedió de igual forma hasta llegar al último nodo desvinculado. En cada instancia, se midió el puntaje del último nodo en la cadena.

**RESULTADOS.** Como se ve en la Figura 10, el puntaje del último eslabón se hace más chico a medida que la cadena se hace más larga. De igual manera, el resultado se acerca progresivamente a  $1/l$ , donde  $l$  es el largo de la cadena.

Podemos ver que la influencia de la página ‘importante’ es fuerte al principio, pero se diluye rápidamente en la cadena. Consideramos que el comportamiento es deseable: Si una página importante apunta a otra, entonces es esperable que aumente la probabilidad que un navegante decida acceder a éste segundo sitio. Pero si agregamos un tercer eslabón en la cadena, entonces la probabilidad que se acceda a ésta tercera página debería ser la intersección de las probabilidades anteriores, y en consecuencia más improbable.

3.2.6. *Escenario 6: Referencias Valiosas.* Cómo varía el peso de una página a medida que cambia la importancia de las páginas que la referencian y el valor de  $p$ <sup>21</sup>.

METODOLOGÍA. Se generaron cien instancias de 102 nodos cada una y se simuló la siguiente situación: inicialmente, el nodo ‘1’ apunta al nodo ‘2’ y todos los demás nodos están aislados. En cada iteración del test se selecciona uno de los nodos aislados, se lo vincula al nodo ‘1’ (en esta misma dirección) y se mide el puntaje de ‘1’ y de ‘2’. Se repitió el experimento para cuatro valores de  $p$  (0.25, 0.50, 0.75 y 0.9999).




FIGURA 11. La influencia de un nodo sobre otro, a medida que cambia su importancia.

HIPÓTESIS Inicialmente el peso del nodo ‘2’ va a ser mayor que el del nodo ‘1’. Nos basamos en la observación que si el nodo ‘1’ no tiene páginas que la referencien y el ‘2’ tiene una referencia, entonces va a ser mayor. A medida que más nodos apunten a ‘1’, el peso de éste va a superar al del nodo ‘2’<sup>22</sup>. Intuímos que la intensidad de esta relación dependerá del valor de  $p$ .

RESULTADOS. Se cumplieron nuestras expectativas. Como se puede apreciar en las Figuras 12 a 15, el valor de  $p$  influenció cómo se transfirió el puntaje de un nodo al otro.

Concluimos que es esencial tener referencias valiosas para aumentar el puntaje en el ranking. Sin embargo, la relación de transferencia no es lineal y depende de  $p$ . Notamos que las páginas con mayor puntaje son también más influyentes y pueden generar cambios radicales en las valoraciones del algoritmo.

Sobre el valor de  $p$  notamos que el mismo funciona como un factor atenuante en la transferencia de puntaje de un nodo a otro. A medida que crece el valor  $p$ , más se transfiere este puntaje. En el caso límite, con  $p$  aproximándose a 1, podemos notar que el valor del segundo nodo se mantiene por encima del nodo ‘referenciador’ a lo largo de todo el espectro. Esto es muy sorprendente y denota la importancia de la elección de  $p$  a la hora de correr el modelo.

<sup>21</sup>Se puede ver el resultado de los experimentos en `./experimentos/resultados/referencias_valiosas`.

<sup>22</sup>Dados los resultados que obtuvimos en el escenario ‘Transitividad en Cadena’.




FIGURA 12. El puntaje de los nodos '1' y '2', donde el primer sitio vincula al segundo, en función del puntaje del primero, para  $p = 0.25$ .

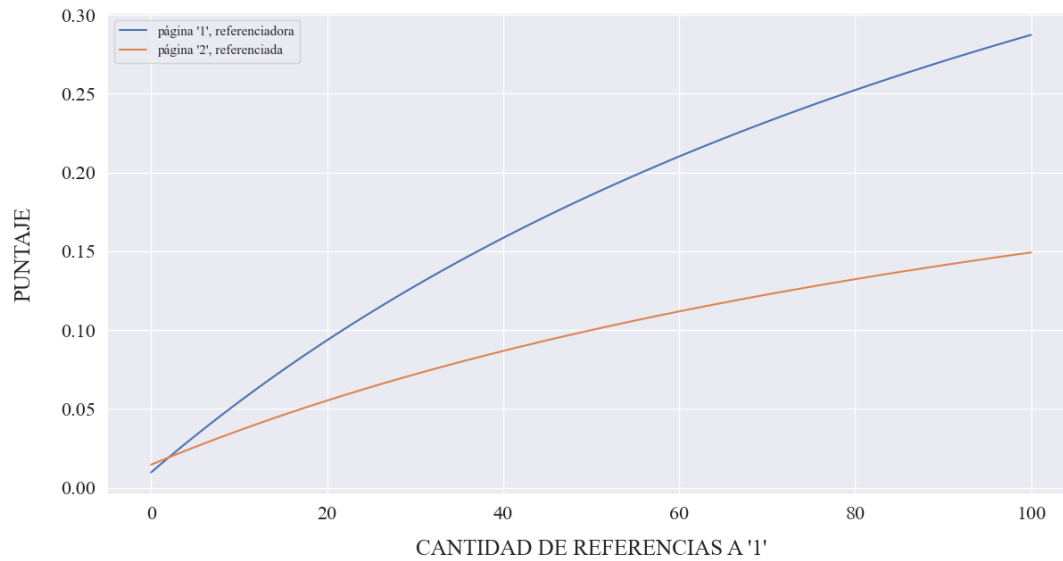


FIGURA 13. El puntaje de los nodos '1' y '2', donde el primer sitio vincula al segundo, en función del puntaje del primero, para  $p = 0.5$ .




FIGURA 14. El puntaje de los nodos '1' y '2', donde el primer sitio vincula al segundo, en función del puntaje del primero, para  $p = 0.75$ .




FIGURA 15. El puntaje de los nodos '1' y '2', donde el primer sitio vincula al segundo, en función del puntaje del primero, para  $p = 0.9999$ .



#### 4. CONCLUSIONES

A lo largo de este informe se articularon una serie de aspectos formales que muestran la solidez matemática del modelo y el algoritmo de *PageRank*. Se realizó una evaluación en profundidad de la implementación propuesta, y se desarrolló una experimentación respecto a las características cualitativas del mismo.

Si bien no se pudieron explorar todas las aristas que se hubieran deseado, pudimos formar una imagen amplia de sus cualidades y funcionamiento.

A simple vista, *PageRank* aparenta ser un modelo formal y muy bien desarrollado para categorizar las páginas con un sustento matemático que lo respalda, pero entrando en detalle se puede observar que es un modelo imperfecto. Puede parecer que la metodología que utiliza *PageRank* imparte un ranking justo, pero hemos visto que, cualitativamente, distintos factores predominan a la hora de generar su jerarquía y, en particular, ciertas páginas dominarán las relaciones del resto y podrán ejercer su influencia.

Si bien hay varios aspectos positivos y deseados como lo demuestran los escenarios de *sin.links* —donde un set de páginas aisladas reciben de manera uniforme su puntaje— o de *Simetria* —donde dos estructuras que están formadas por links entrantes y salientes de igual importancia reciben la misma valoración—, también hay aspectos negativos que permiten manipular el sistema.

A partir de los casos analizados, se vislumbran ciertas estrategias que permitirían influenciar el ranking: generar páginas descartables con links a la que querríamos inflar artificialmente, no poner vínculos a otras páginas para evitar elevar sus rankings, lograr que páginas importantes nos referencien... es decir: el crecimiento de una página podría ser inorgánico, generando un efecto contraproducente, donde muchas páginas que no ofrecen un contenido valorable posean un ranking elevado, simplemente por conocer el mecanismo de crecimiento.

Un último factor pendiente a mencionar es el del valor  $p$ . Como vimos, el mismo tiene una influencia notable en las cualidades del ranking. Tanto desde el aspecto del error numérico, como de su influencia en la elaboración de los puntajes. Pudimos notar que sirve como un factor atenuante de las ponderaciones y por ello tiene un rol crucial a la hora de lograr una jerarquía lo más justa posible.

Consideramos que *PageRank* fue una idea revolucionaria, marcó la industria e influyó la forma en que navegamos la web. Pero consideramos que el sistema quedó obsoleto para la internet actual, donde la cantidad de actores que obran para influenciar los resultados y la disparidad de cualquier ranking genérico con los intereses particulares de cada navegante, lo vuelven —en nuestra opinión— poco efectivo para jerarquizar los resultados en comparación a métodos más modernos.

## 5. APÉNDICE

5.1. **A:**  $A = pWD + ez^t$ .

*demostración.* Recordemos que:

$$e_i = 1$$

$$z_j = \begin{cases} (1-p)/n & \text{si } c_j \neq 0 \\ 1/n & \text{si no} \end{cases}$$

$$w_{ij} = \begin{cases} 1 & \text{si } i \neq j \wedge j \xrightarrow{l} i \\ 0 & \text{si no} \end{cases}$$

$$d_{ij} = \begin{cases} 1/c_j & \text{si } i = j \wedge c_j \neq 0 \\ 0 & \text{si no} \end{cases}$$

A partir de estas definiciones, vemos que, como **D** es diagonal, el producto a derecha **WD** escala cada columna  $w_j$  por el factor  $d_{jj}$ , tal que:

$$(\mathbf{WD})_{ij} = \begin{cases} w_{ij}/c_j & \text{si } c_j \neq 0 \\ 0 & \text{si no} \end{cases}$$

Como  $p$  es un escalar, sigue entonces que:

$$(p\mathbf{WD})_{ij} = \begin{cases} p \cdot w_{ij}/c_j & \text{si } c_j \neq 0 \\ 0 & \text{si no} \end{cases}$$

Además,  $e \in \mathbb{R}^{n \times 1} \wedge z^t \in \mathbb{R}^{1 \times n} \implies ez^t \in \mathbb{R}^{n \times n}$ , y:

$$(ez^t)_{ij} := \sum_{k=1}^1 e_{ik} \cdot z_{kj}^t = e_i \cdot z_j^t = 1 \cdot z_j^t = z_j$$

Por lo que:

$$\begin{aligned} (p\mathbf{WD} + ez^t)_{ij} &= \begin{cases} p \cdot w_{ij}/c_j + z_j & \text{si } c_j \neq 0 \\ z_j & \text{si no} \end{cases} \\ &= \begin{cases} (1-p) \cdot \frac{1}{n} + p \cdot \frac{w_{ij}}{c_j} & \text{si } c_j \neq 0 \\ \frac{1}{n} & \text{si no} \end{cases} \end{aligned}$$

pero:

$$a_{ij} := Pr(j \longrightarrow i) = \begin{cases} (1-p) \cdot \frac{1}{n} + p \cdot \frac{I_{ij}}{c_j} & \text{si } c_j \neq 0 \\ \frac{1}{n} & \text{si no} \end{cases}$$

Como  $I_{ij} = 1$  si y sólo si existe un hipervínculo de  $j$  a  $i$ , con  $j \neq i$  —y nulo en caso contrario—, entonces  $I_{ij} = w_{ij}$  y concluimos que  $a_{ij} = (p\mathbf{WD} + ez^t)_{ij} \quad \forall i, j : 1 \dots n$ , lo que implica que:

$$\mathbf{A} = p\mathbf{WD} + ez^t$$

■

## 5.2. **B: $I - pWD$ permite la eliminación gaussiana.**

*Demostración.* Demos primero una definición formal del enunciado:

ELIMINACIÓN GAUSSIANA.  $\forall \mathbf{A} \in \mathbb{R}^{n \times n}$ ,  $\exists! m \in \mathbb{N} : 1 \leq m \leq n$  tal que:

$$\forall k \in \mathbb{N} : 1 \leq k < m$$

$$eg_1(\mathbf{A})_{ij} = a_{ij}$$

$$eg_{k+1}(\mathbf{A})_{ij} = \begin{cases} eg_k(\mathbf{A})_{ij} & \text{si } i < k+1 \vee j < k+1 \\ eg_k(\mathbf{A})_{ij} - \frac{eg_k(\mathbf{A})_{ik}}{eg_k(\mathbf{A})_{kk}} \cdot eg_k(\mathbf{A})_{kj} & \text{si no} \end{cases}$$

donde  $m < n$  es el mínimo valor que satisface que  $eg_m(\mathbf{A})_{mm} = 0$ . Si la matriz  $\mathbf{A}$  es tal que  $m = n$ , entonces  $\mathbf{A}$  permite la eliminación gaussiana.

Probaremos que para la matriz  $\mathbf{B} \in \mathbb{R}^{n \times n} = \mathbf{I} - p\mathbf{W}\mathbf{D}$ ,  $\forall k \in \mathbb{N} : 1 \leq k \leq n$ :

$$eg_k(\mathbf{B})_{kk} \neq 0$$

y en consecuencia  $m = n$ .

Para ello demostraremos el siguiente enunciado:

$$|b_{jj}^k| > \sum_{i=k, i \neq j}^n |b_{ij}^k| \quad \forall k, j \in \mathbb{N} : 1 \leq k \leq j \leq n$$

donde  $b_{ij}^k = eg_k(\mathbf{B})_{ij}$ .

Es decir, para todo paso  $k$  de la eliminación gaussiana se satisface que el valor absoluto de los elementos de la diagonal mayores o iguales a  $k$  son mayor estricto al valor absoluto de la suma de los elementos de su columna desde la posición  $k$ , descontando la diagonal.

Lo demostraremos por inducción:

$$\forall k, j \in \mathbb{N} : 1 \leq k \leq j \leq n$$

$$|b_{jj}^k| > \sum_{i=k, i \neq j}^n |b_{ij}^k| \implies |b_{jj}^{k+1}| > \sum_{i=k+1, i \neq j}^n |b_{ij}^{k+1}|$$

CASO BASE ( $k = 1$ ):

Notemos primero que

$$(\mathbf{B})_{ij} = (\mathbf{I} - p\mathbf{WD})_{ij} = \begin{cases} 1 & \text{si } i = j \\ -p/c_j & \text{si } w_{ij} = 1 \wedge c_j \neq 0 \\ 0 & \text{si no} \end{cases}$$

Dado que todo elemento de cada columna  $j$  de  $\mathbf{WD}$  está normalizado por  $1/c_j$ , tal que su suma da uno, entonces la suma de la columna  $(-p\mathbf{WD})_j = -p$ , con  $0 < p < 1$ .

Observamos también que la diagonal es nula para esta matriz, tal que su suma por  $\mathbf{I}$  da  $(\mathbf{I} - p\mathbf{WD})_{jj} = 1$ . Este tipo de matriz se conoce como estocástica en columnas y su transpuesta es diagonal dominante.

En consecuencia, es inmediato que  $|b_{jj}^1| = |b_{jj}| = 1 > \sum_{i=k, i \neq j}^n |b_{ij}^1| = |-p| \forall j \in \mathbb{N} : 1 \leq j \leq n$ . □

PASO INDUCTIVO:

$\forall j \in \mathbb{N} : 1 \leq k \leq j \leq n$

$$\begin{aligned} |b_{jj}^{k+1}| &> \sum_{i=k+1, i \neq j}^n |b_{ij}^{k+1}| \\ \iff |b_{jj}^k - \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k}| &> \sum_{i=k+1, i \neq j}^n |b_{ij}^k - \frac{b_{ik}^k \cdot b_{kj}^k}{b_{kk}^k}| \end{aligned}$$

dado que  $|a - b| \geq |a| - |b| \wedge |a| + |b| \geq |a + b|$  por desigualdad triangular, entonces podemos demostrar equivalentemente, por teorema del sandwich, que:

$$|b_{jj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| > \sum_{i=k+1, i \neq j}^n |b_{ij}^k| + \sum_{i=k+1, i \neq j}^n \left| \frac{b_{ik}^k \cdot b_{kj}^k}{b_{kk}^k} \right|$$

Como:

$$\sum_{i=k+1, i \neq j}^n |b_{ij}^k| = \left( \sum_{i=k, i \neq j}^n |b_{ij}^k| \right) - |b_{kj}^k|$$

y por hipótesis inductiva:

$$|b_{jj}^k| > \sum_{i=k, i \neq j}^n |b_{ij}^k| \implies |b_{jj}^k| - |b_{kj}^k| > \left( \sum_{i=k, i \neq j}^n |b_{ij}^k| \right) - |b_{kj}^k|$$

entonces podemos volver a acotar tal que:

$$|b_{jj}^k| - |b_{kj}^k| + \sum_{i=k+1, i \neq j}^n \left| \frac{b_{ik}^k \cdot b_{kj}^k}{b_{kk}^k} \right| >_{hi} \sum_{i=k+1, i \neq j}^n |b_{ij}^k| + \sum_{i=k+1, i \neq j}^n \left| \frac{b_{ik}^k \cdot b_{kj}^k}{b_{kk}^k} \right|$$

y considerar que:

$$\begin{aligned} |b_{jj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| &\geq |b_{jj}^k| - |b_{kj}^k| + \sum_{i=k+1, i \neq j}^n \left| \frac{b_{ik}^k \cdot b_{kj}^k}{b_{kk}^k} \right| \\ \iff |b_{kj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| &\geq \frac{|b_{kj}^k|}{|b_{kk}^k|} \sum_{i=k+1, i \neq j}^N |b_{ik}^k| \end{aligned}$$

Podemos acotar una última vez, tal que:

$$|b_{kj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| \geq \frac{|b_{kj}^k|}{|b_{kk}^k|} (|b_{kk}^k| - |b_{jk}^k|) >_{hi} \frac{|b_{kj}^k|}{|b_{kk}^k|} \sum_{i=k+1, i \neq j}^N |b_{ik}^k|$$

Pero:

$$|b_{kj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| \geq \frac{|b_{kj}^k|}{|b_{kk}^k|} (|b_{kk}^k| - |b_{jk}^k|) \iff |b_{kj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right| \geq |b_{kj}^k| - \left| \frac{b_{jk}^k \cdot b_{kj}^k}{b_{kk}^k} \right|$$

Lo que es trivialmente cierto. □

Demostramos ahora por absurdo que  $b_{kk}^k \neq 0 \quad \forall k \in \mathbb{N} : 1 \leq k \leq n$ .

Supongamos que existe algún  $k$  tal que  $b_{kk}^k = 0$ . Entonces:

$$|b_{kk}^k| = 0 > \sum_{i=k, i \neq k}^n |b_{ij}^k| \quad \forall j \in \mathbb{N} : 1 \leq k \leq j \leq n$$

Pero  $\sum_{i=k, i \neq k}^n |b_{ij}^k|$  es necesariamente una suma de valores positivos ó 0. Es decir:

$$0 > \sum_{i=k, i \neq k}^n |b_{ij}^k| \geq 0 \implies 0 > 0$$

Absurdo! ■

5.3. **C: Alternativas de diseño.** A la hora de decidir cómo representar las matrices se evaluaron las siguientes alternativas:

- Como estructura ‘base’, utilizar un vector de  $n$  vectores de tamaño fijo  $n$ . VENTAJAS: se puede acceder y modificar los elementos en  $\Theta(1)$ . DESVENTAJAS: requiere iterar sobre todos los elementos de la matriz, es ineficiente en espacio y —para matrices muy grandes— probablemente requiera más accesos a disco.
- Una estructura ‘alt’ con un vector de  $n$  vectores de tamaño variable donde en cada lugar se guarda la tupla  $\langle \text{posicion}, \text{elemento} \rangle$ . VENTAJAS: es más eficiente en espacio, permite iterar sobre los elementos no nulos de cada fila y acceder a estas en  $\Theta(1)$ . DESVENTAJAS: El acceso a cada columna —con búsqueda binaria— tiene un peor caso en  $\Theta(\log(n))$  y la inserción tiene un peor caso en  $\Theta(n)$ .
- La misma estructura pero con listas enlazadas. VENTAJAS: permite la inserción en  $\Theta(1)$  e iterar sobre los elementos no nulos de cada fila con la misma complejidad. DESVENTAJAS: el acceso es en  $\Theta(n)$  y no mantiene memoria contigua, por lo que hay mayor probabilidad de cache-miss.
- Una ‘matriz enlazada’ donde cada nodo apunta al próximo elemento no nulo de la misma fila y columna. VENTAJAS: permite iterar sobre los elementos no nulos de cada fila y columna en  $\Theta(1)$ . DESVENTAJAS: las mismas que la lista enlazada.
- Utilizar alguna estructura de diccionario como  $\langle \text{map} \rangle$ . Las ventajas y desventajas son similares a la de la estructura alternativa si se mantienen las claves en orden y se pueda iterar sobre ellas en  $\Theta(1)$ .

Todas estas posibilidades motivaron la elaboración de un código genérico que permitiera el intercambio de las representaciones. La clase *matriz*  $\langle R \rangle$  definida en *./implementacion/* provee una interfáz de matriz completa junto a la implementación de muchos de sus métodos.

Una representación  $R$  deberá definir sólo aquellas operaciones que conciernen el acceso a datos. Para lograr esta modularización se tomaron dos decisiones importantes:

- Se optó por la transparencia referencial de todas las operaciones. Para las representaciones contempladas, generar una nueva instancia es más rápido que modificar la estructura actual.
- Todos los algoritmos están implementados para evitar las operaciones redundantes. Par ello, se optó por que cada representación implemente iteradores específicos.

Estas decisiones tienen una clara desventaja: el código provisto por *matriz*  $\langle r \rangle$  podría ser optimizado para cada representación subyacente. Sin embargo, se priorizó la facilidad de la experimentación sobre la optimalidad del código.

Siguiendo esta metodología, se implementaron dos de las alternativas propuestas: ‘base’ y ‘alt’ y acorde a los resultados vistos, se optó por ‘alt’.

## REFERENCIAS

- [1] Sergey Brin and Lawrence Page. The anatomy of a large-scale hypertextual web search engine. *Computer networks and ISDN systems*, 30 (1-7):107–117, 1998.
- [2] Kurt Bryan and Tanya Leise. The \$25,000,000,000 eigenvector: The linear algebra behind google. *T SIAM review*, 48 (3):569–581, 2006.
- [3] Amy N Langville and Carl D Meyer. Deeper inside pagerank. *Internet Mathematics*, 1(3):335–380, 2004.
- [4] Sepandar D Kamvar; Taher H Haveliwala; Christopher D Manning and Gene H Golub. Extrapolation methods for accelerating pagerank computations. *In Proceedings of the 12th international conference on World Wide Web*, pages 261-270. ACM, 2003.